

Proyecto 3 - Frameworks y herramientas para big data: Uso de Arquitectura Lakehouse en Azure Databricks con pipeline de ingesta y cargue de datos.

Profesor: Oscar Andrés Jiménez Villanueva.

Objetivo:

Con base en la arquitectura lakehouse desplegada previamente en Databricks, se debe migrar el pipeline de datos desarrollado en el segundo proyecto basado en arquitectura open source.

En este caso, no se usará dlt para ingestar de datos sino que debe ser mediante cualquier otra librería de python, puede ser request o leer el archivo con pyarrow.

Adicionalmente, solo se debe usar un año para los datos ya que no queremos procesar tantas cantidades de datos y procurar ahorrar en los créditos. **Usar al menos dos meses por tabla.**

El proyecto debe implementar la **arquitectura Medallion (Bronze → Silver → Gold)** con lógica de ingesta, transformación, calidad de datos y agregación.

Infraestructura Requerida:

- Azure data lake Gen 2 (object storage)
- Unity Catalog (catálogo de metadatos)
- Delta table (table format)
- Apache Spark con PySpark (procesamiento)
- Databricks Jobs (orquestración)
- Databricks Notebook (ejecución manual alterna)
- Uso de DuckDB para consultar las tablas delta de silver y gold.

Arquitectura Medallion:

- **Bronze**
 - Almacenamiento en **Parquet**.
 - Sobrescritura (override) permitida.
 - Contenido: datos crudos diarios (mensuales) de la fuente seleccionada.
 - Cargar dos meses seguidos de un mismo año.

- **Silver**

- Tablas en formato **Delta**.
- Escritura con **merge** (no override), para manejar duplicados y cambios históricos.
- Validar cantidad de registros nuevos o actualizar.
- Contenido: tablas curadas y normalizadas e históricas
- Cargar 2 meses de un mismo año.
- Deben tener columna de fecha de cargue.

- **Gold**

- Tablas en formato **Delta**.
- Escritura con **merge**, con reglas de negocio y agregaciones.
- Validar cantidad de registros nuevos o actualizar.
- Deben tener columna de fecha de cargue.
- Contenido: métricas, KPIs y tablas analíticas.

Orquestación (Databricks):


- Job con al menos 3 tareas:
 1. Ingesta Bronze.
 2. Transformación Silver (PySpark + Delta).
 3. Agregación Gold (PySpark + Delta).
- El Job debe poder ejecutarse completo con un solo “Play” en Databricks.

Ejecución manual (Databricks Notebooks):

- Tres notebooks/scripts independientes:
 - bronze_ingest.ipynb
 - silver_transform.ipynb
 - gold_agg.ipynb
- Cada script debe poder ejecutarse manualmente en caso de fallo en el Job.

Dataset:

- Dataset base recomendado: **StackOverflow dataset (ClickHouse)**
<https://clickhouse.com/docs/getting-started/example-datasets/stackoverflow>
- Tablas incluidas: Posts, Users, Votes, Comments, Badges, PostLinks, PostHistory.



- Los estudiantes pueden usar este dataset o elegir otro siempre que cumpla con:
 - Al menos **2 tablas** o fuentes para ser mezcladas.
 - Datos con relaciones (para poder hacer joins).
 - Volumen razonable (no excesivo).

Ejemplos de Tablas en Gold:

Algunas tablas esperadas o de ejemplo:

- **post_counts_by_user**: número de preguntas y respuestas publicadas por usuario.
- **vote_stats_per_post**: votos positivos/negativos por post.
- **top_tags** → ranking de etiquetas con mayor número de preguntas.
- **user_engagement** : interacciones de cada usuario (posts, comentarios, votos, badges).
- **badges_summary** : número y tipo de insignias obtenidas por usuario.

Criterios de Calificación:

1. Entregables – 40%

- Notebooks de ejecución (bronze_ingest.ipynb, silver_transform.ipynb, gold_agg.ipynb).
- Notebook del orquestador que ejecutará los tres notebooks.
- Diagrama de la arquitectura medallón implementada y cómo viajan los datos entre las capas.

2. Infraestructura – 10%

- Todos los servicios están ejecutándose en un grupo de recursos. Cuenta de almacenamiento, Key vault, access connector, Databricks.

3. Pipeline – 30% (10% cada etapa)

- **Bronze:** ejecución correcta, almacenamiento Parquet con override.
- **Silver:** ejecución correcta con escritura en Delta usando **merge y validando cantidades de registros nuevos o por actualizar**.
- **Gold:** ejecución correcta con escritura en Delta usando **merge y validando cantidades de registros nuevos o por actualizar**, generando agregaciones y métricas.

En caso de fallo del Job, se evaluará la ejecución manual de los notebooks.

4. Consumo y Consulta - 5%

- Tablas disponibles de silver y gold consultadas desde DuckDB.

5. Visualización de las tabla de gold - 15%

- Conectar Databricks con Power BI y realizar una visual de un tablero sencilla con base en la métricas de la tabla de Gold.